第 13 章　集成电路时代

历史是纷繁复杂的，科学却要分门别类。但是，如果你看得仔细些，各门学科之间都是互相借鉴、互相学习的，就这样向前发展。

一开始，电学在磨磨蹭蹭地往前走，当然是越来越快。于是电磁铁发明了，也有了继电器。这个时候，电子计算机的先驱们也正处在彷徨之中，看到了继电器，觉得这东西挺好，都是合用的东西，可以拿过来用用。基本上，在 20 世纪 30 年代，他们都是在用继电器造那些最原始的计算机器。他们造的机器，有的非常庞大，用了数不清有多少继电器，工作起来啪啪啦啦，声势雄壮，煞是热闹，那阵势，那场面，据亲临现场的人说，“像是挤满了一屋子纺织绒线的妇女。”

在没有多少东西可供选择的年代，电子管和晶体管是最理想的选择。但是它们也有自己的缺陷，指望用这两样东西来制造一台你面前的这种计算机，是不可能的。好在我们只是重温历史，现在，当你坐下来使用计算机的时候，或者气喘吁吁地抱着新买的计算机喜滋滋地往家里搬的时候，你大概会愿意想到，究竟是发生了什么翻天覆地的变化，才使得我们现在的计算机变得如此紧凑而轻巧呢？它都经历了哪些艰难曲折的演变过程？

13.1　电子管和晶体管时代

电子计算机用上继电器是在 20 世纪 30 年代，那个时候，电视机都已经有了，但是电子计算机的研究刚刚获得突破。要是再早些，当弗莱明发明电子二极管、福雷斯特发明电子三极管的时候，这方面的进展就更别提了，连萌芽都谈不上，完全是——哎呀，一片沉寂。唯一的例外是触发器的发明，那是 1918 年。尽管这项技术在十几年后为计算机的发展带来了福音，但这并不是发明者当初的愿望。

时间过得很快，到了 20 世纪 30 年代，当电子三极管由于制造工艺的成熟和价格的降低，其应用如雪崩般开始的时候，香农也已经完成了把布尔的数字逻辑系统与继电器相结合的工作。正如我们现在已经知道的那样，当时已经出现了为数不少的继电器计算机。当然，这都是一个个的“小玩具”，要让它们真正变得实用，能解决复杂的问题，而且速度还要快，就必须使用电子管。

到了 20 世纪 40 年代，程序存储——也就是把程序放在存储器里，由计算机自动执行的思想已经开始为越来越多的人所接受。另一方面，人们也注意到，继

电器的速度很慢，而电子管则比它快千万倍。使用电子管，不但可以产生频率很高的时钟脉冲供计算机内部顺序控制之用，而且用它制成的与、或、非逻辑电路也能以极快的速度工作。但是，制造这样一台可以存储程序并自动进行计算的机器需要的并不仅仅是胆识，还有钱。

一般来说，商人、政府和军方有的是钱，只是要劝说他们把钱拿出来，你得有充分的证据表明制造一台电子计算机将会获得几倍甚至更多的回报，或者它能把来犯之敌吓跑或消灭。不过，既然有实力能掏出大笔钱来，这帮人都不傻。

1943年，第二次世界大战正打得不过开交，美国军方需要为他们的新式火炮制作弹道表。为了赶时间，这一次他们倒是很痛快地斥巨资要科学家们帮助造一台计算机。毕竟，在大难临头的时候，你是选择金钱，还是死亡？

这台机器每秒钟能做5 000次加法，用了成千上万的电子管和继电器，耗时3年，当它好不容易完成的时候，战争已经结束了。

懂得电学的人都知道，继电器和电子管的个头都不是特别小，而且都不是省油的灯。所以，由于用了成千上万个这样的东西，这台机器不但在体积上大得惊人，耗电量也同样大得惊人。据说当时只能在晚上夜深人静的时候把它打开（反正战争已经结束了，别的事情没几样是必须争分夺秒的），要不然当地居民家里的电灯都会变得黯淡无光。

一台计算机应当包括一个存储器和一个运算器，指令和数据都放在存储器里，在控制器的指挥下一条指令一条指令地自动执行。这种安排正是从这个时候开始的，一直沿用到现在。由于第一个提出采用这种结构形式并积极把这种设想付诸实施的是数学家、计算机专家、美籍匈牙利人冯·诺依曼，所以又称为“冯·诺依曼体系结构”。当然，这不是唯一的计算机体系结构，我建议你在有闲情逸致的时候了解一下什么是哈佛体系结构。

这个世界既现实又势利，令人迷惑。当一名妇女在机场看到自己十几年前无比崇拜的电影明星时，依然激动得心里呼呼直跳，而对于像钱学森、袁隆平这样的科学家，她们却记不住。她们不知道——也许有些夸张——如果没有像袁隆平这样的人，我们可能会饿得没有力气和心思进电影院的大门。尽管我们无法想象这个国家的所有人都和袁隆平、华罗庚、钱学森一样杰出会是什么样子，但更无法想象要是都成不了这样的科学家会怎样。科学家可以远离鲜花和掌声，忍受漫漫长途中的孤独和寂寞，但我们却不应该忘记他们。冯·诺依曼指引了现代计算机的发展方向，被誉为“计算机之父”，但是却一直站在后排而不为人知。在少数情况下，人们也会提到他，夸他两句；而在另一些时候，人们记住他，只是因为他曾经大嘴一张，傻乎乎地声称有4台计算机就足够全世界使用。

这也不能全怪他。在那个时代，计算机庞大、昂贵、操作复杂，需要一大堆专家才能侍候得了，毫无疑问，这也使得它很神圣。像这样一种东西，所有生活

在那个时代的人都会很自然地觉得它应该被供起来，只有那些复杂的和重要的数学问题才配在这样的机器上算一下。这是一种在诞生的时候离普通人的生活过于遥远的东西，人们只希望它应当越来越强大，越来越快，但是，普通人用不上的东西，造那么多有什么用呢？难怪同时代著名的科幻作家阿西莫夫也这样预言："一台计算机最终会有几十亿个电子管，有一个国家那么大。"不过，阿西莫夫不应当为没看到这么巨大的计算机而感到遗憾，因为不单单是他，连我们都没见过。

所幸的是，正如我们已经知道的那样，晶体管适时地被发明出来了。此时，电子计算机已经上了路，相关的理论也已经相当完备。现在，它只要有一个强大的推进器，就可以跑得像海牛一样迅速。这也是第一次它能够用最短的时间搭上其他物理学发明的便车。

世界上第一台晶体管计算机诞生于肖克利获得诺贝尔奖的那一年，即 1956 年。领先一步的工程师们有幸参与其中，目睹了采用晶体管的电子计算机成功减肥，既不需要灯丝，也不需要高电压，工作稳定，还不像从前那样费电，连续工作时间大大延长，功能也进一步增强——这是明摆着的，只有新的技术才能缩小体积、降低成本，当耗电量大幅度减少，计算机的体积也不再是科学家的心理负担时，可以放心大胆地设计出更多新功能的电路。没有更好的技术，你可能还在用皂角树上的果实洗衣服，坐在池塘旁边用木棍使劲儿捶打，这就是进步。

说来也巧，同样是在 1956 年，周恩来总理亲自提议、主持、制定我国《十二年科学技术发展规划》，选定了"计算技术、半导体技术、无线电电子学、自动学和远距离操纵技术"作为"发展规划"的四项紧急措施，并制订了计算机科研、生产、教育发展计划。同年 8 月 25 日，我国第一个计算技术研究机构——中科院计算技术研究所筹备委员会成立，主任就是大数学家华罗庚，这里就是我国计算技术研究的摇篮。

前面所罗列的这几项技术对国民经济的重要性是不言而喻的，但是对于我们这样一个国家，百年来战乱不断，受尽外侮，现在说要搞计算机，谈何容易？不过，在前苏联的援助下，1958 年 8 月 1 日，我国第一台小型电子管计算机诞生，编号 103。该机字长 32 位、每秒运算 30 次，时任中国科学院党组书记的张劲夫曾风趣地说，这台计算机叫"有了"。

电子管的发明使制造一台真正的电子计算机成为可能，而晶体管则使它坐上了新式的快艇。不过，这两样宝贝还是无法全副武装电子计算机，实际上还差得远呢。你可以用它们制造运算器和寄存器，一是没有办法，二是需要不了多少寄存器这样的东西。但是，没有人舍得用电子管和晶体管来制造存储器，至于用继电器来制造存储器，那更是历史上从来没有发生过的事情。

我们已经知道，1 个字节（B）实际上包含了 8 个比特（b），要计量二进制数据，字节是最基本的单位。比字节更大的是千字节（KB）：

1KB = 1 024B

比千字节更大的是兆字节（MB）、吉字节（GB）和太字节（TB）。它们之间的换算关系是：

1MB=1 024KB

1GB=1 024MB

1TB=1 024GB

一般的，保存 1 个比特的成本相当于好几个电子管或者晶体管，而 1 个字节则需要几十个。算下来，1KB 的存储器就需要好几万个。我知道大家都喜欢 MP3 随身听，一首歌平均有 3MB 的数据量，100 首就有 300MB。别看你现在可以把 300MB 的数据挂在胸前，走到哪儿听到哪儿，要在以前的时代，做成这样的存储器需要 5 000 000 000 只电子管或者晶体管，真想动手做一个？那简直是疯了，别说挂在胸前四处招摇，就是装在车上你也拉不动。

13.2 集成电路时代

在翻过了肖克利这一页之后，晶体管没有停滞不前，而是以更快的速度改变着整个世界。我们已经说过，晶体管实际上可以做得很小，小到连肉眼都看不见。但是，如果没有其他物理化学工艺上的支持，这都是白扯。如果没那么大野心的话，因陋就简，来个简单的也不是不可能。

1958 年，也许是受够了在一大堆晶体管里连接杂乱无章的导线，一个叫杰克·基尔比的美国人决心要做些什么来改变这一切。基尔比为人随和，不大爱说话，身高两米左右，在大家的眼里，他是一个务实的好人，一个“温和的巨人”——他以前的同事们就是这样说的。

差不多和所有刚到一个新单位上班的人一样——反正有人是这么说的——当所有员工都在外面放松身心的时候，他们打发基尔比留在办公室里欢度假期。基尔比的新工作是研究晶体管电路的小型化，希望能够有所建树符合这个 35 岁中年男人的愿望。这个时候，他突然觉得自己开了窍——他想，一个大的电路要使用很多零件，比如晶体管和电阻这些东西。如果换一个视角来观察这个电路的工作，你会发现电流不过是从一块掺杂的硅里出来，经过导线之后，又流入另一块掺杂的硅里，本质上就是这么简单。为什么不把连接线去掉，让电流直接从一个掺杂区域流到另一个掺杂区域呢？

这有点儿像什么？就像几个人平时住得很分散，要到彼此家里串门儿还得走两步，坐上车，转几个弯儿，七拐八拐地才能到。现在好了，他们住在有好多间屋子的大房子里，彼此要到对方那里仅仅是从一个屋子走到另一个屋子那么简单。

就这样，基尔比发明了集成电路[1]。这世界上第一块集成电路，他做的是一个振荡器，里面包含的零件不到十个。2000 年，在距离他发明第一块集成电路 42 年之后，他获得了诺贝尔物理学奖。

1959 年，有一个叫罗伯特·诺伊斯的人发明了一种新的工艺，可以在一块本征硅上制造大量晶体管。这个人以前是肖克利的弟子，早年和其他人一样，因为仰慕老肖而在他手下工作。后来这帮人因为无法继续忍受老肖的作风而集体叛逃，诺伊斯就是其中之一。肖克利从此以后非常憎恨这帮人，见了面连招呼都不愿打，这当然已经和本书无关了。诺伊斯的新工艺完全建立在一套工艺流程之上，具备在工厂流水线上批量生产的条件，这在当时是了不得的。

从诺伊斯发明这种工业化生产集成电路的方法开始，在随后的几十年里，这种技术改进了好多回，每改进一回，集成的晶体管数量都会千百倍地增加。刚开始的时候，在指甲大小的硅片上可以集成几十个，到了现在，这个数量可以达到几千万个，甚至更多。图 13.1 显示了两种常见的集成电路。

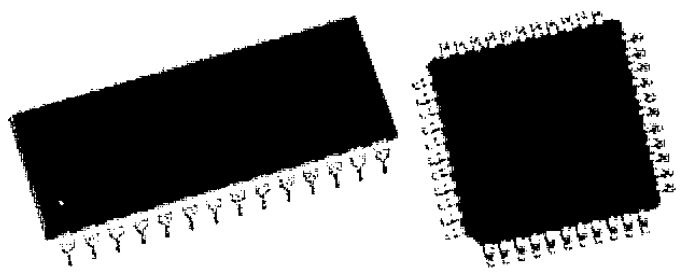

图 13.1　两种常见的集成电路外观

比起晶体管来，集成电路更小、更便于使用，而且耗电量更低，这是它具有光明前途的优良特征。它应当被迅速应用到电子计算机上，不是吗！

我们知道，磁芯曾经是制造存储器的主要材料。但是，集成电路的特点使得它很适合用来制造半导体存储器，于是一大批半导体存储器制造厂商诞生了，并很快终结了磁芯长达二十年的应用历史，独步天下，一直走到今天。以前，用 5 000 000 000 只晶体管做一个大容量的存储器还是梦想，甚至想都不敢想，现在却可以很轻松地把它们做在指甲大小的一块硅片上。和以前一样，晶体管是构建触发器的材料，然后大量的触发器又可以形成大容量的存储器。传统上，这就是静态存储器（Static Random Access Memory，SRAM）的制造方法。至于磁芯，除了博物馆和大公司里布满灰尘与蛛丝的仓库之外，已经看不到它们的踪影了。唯一的例外是英语单词“core”，过去它指的是磁芯，直到今天它依然被用来指代存储器。现代的计算机经常会出现一些小小的故障，如果在偶然的情况下，当你看到显示器上出现“Exception encountered: core dump”这样一段话时，除了意识到

① 也就是我们经常所说的 IC，它是英语 Integrated Circuit（集成电路）的缩写。一个具有某种功能的集成电路也叫芯片。

自己碰上了麻烦，或许还能感受到磁芯曾经给这个世界带来的深远影响。

触发器的工作速度很快，所以静态存储器一直是制造计算机存储器的首选。遗憾的是，在那个时候，采用触发器来构建大容量存储器需要集成太多的晶体管——基本上是5～6个晶体管才能保存1个比特，既不利于提高集成度，也无法降低成本。但是聪明的人们很快想到了其他方法，使得要存储1个比特，只用一只晶体管和一个电容就能办到。

最早的电容器是18世纪发明的莱顿瓶，通常人们也把它看成是人类历史上第一个电池。在荷兰这个国家，有一个叫莱顿的城镇；城里有一所大学，叫莱顿大学；莱顿大学里有一个爱好实验的教授，叫马森布洛克（1692—1761年）。马森布洛克教授最大的发明是一个瓶子，它的内、外壁都贴着一层金属箔。那是电学发展的早期，当时人们已经懂得用塑料和毛皮摩擦来产生静电。马森布洛克无意中发现，通过摩擦产生的静电可以在这个特殊的瓶子里储存起来。

马森布洛克的发明连他自己都感到害怕。在无意中给莱顿瓶充上静电之后，没多久，当他晃悠到这个瓶子旁边时，又同样在无意中遭到了静电的重重一击。在回过神来之后，他依然说不清那是一种什么感受，像是被人揍了，但又不完全是那种感觉。他只是想，这辈子再也不愿意有这样的经历了。

作为一个新的发明，人们将其称为莱顿瓶。其实，它就是两个分开的金属板。是的，最普通的电容器就是由两块金属板隔着一定距离构成的。另外，同样不用怀疑的是，随便两根电线摆在一起也是一个电容器；两个人站在一起还是一个电容器；当你站在厨房里用铁锅炒菜时，你和铁锅之间也构成了一个电容器。

所有的电容器都有一个特点，那就是把它接到电源上时，在电源的作用下，一个金属板上的电子会被拉到另一个金属板上，从而，当电源撤走之后，这两块金属板会保持着一块电子多余而另一块电子缺乏的状态，以至于在它们之间存在电压。如果仅仅从感官上判断，好像是电容器可以储存电，这就是电容器的由来。

听起来是一件可怕的事情，因为所有的金属都可以构成电容器，要是它们之间存在电压，那将是很危险的。当然，有时候的确很可怕，马森布洛克就是一个例子。不过，印象中距离很近的导体随处可见，也没见它们有多厉害，这是为什么？

事实上，电容器容量的大小既和两个极板的面积与距离有关，也和它们中间都填充了些什么东西有关。如果极板面积不大，而且中间隔着空气，没有充过电，或者充电电压很低，那就感觉不到有什么危险。但要是你从电视机里拆一个大家伙，可以试试用手摸一下它的引脚，相信一定会给你留下深刻的印象。在这种电容器里，有着储电效果非常好的电解液。

充了电的电容器可以通过其他导电体放电，这相当于一个电池。确实，在有些计算机上，或者一些电子产品里（手机、电子表），通常用电容来短时间维持电

路的工作。当你把手机电池取下来之后，日期和时间能维持一会儿。要是你过了很长时间才把电池安上，就只能重新设定当前的日期和时间了。

放电的速度取决于两个极板之间的电阻。可以利用电容器充放电的特点来保存1个二进制比特。充了电的电容器相当于保存了“1”，而没有充电的则是“0”。这样，用一只具有开关效能的新型晶体三极管和一只电容就可以存储一个比特。当外部的地址译码器选中这个单元时，三极管打开，电容器可以通过它向数据线放电，或者从数据线上接受充电，这分别相当于读取和写入。历史上第一个采用单只晶体管制造存储器的人是罗伯特·登纳德，他在1968年申请了专利。

电容器在充电之后，即使放在那里不用，也会通过隔在两极间的空气或者其他介质慢慢放电，这称为泄漏。尽管它有这个讨人嫌的毛病，但是，用人之道是发挥人才的长处，而不是成天盯着人家的短处。由于晶体管和电容器可以做得非常微小，这样就能得到密度和容量很大的集成电路存储器，而且成本低，价格便宜。不过，让我们感到惊奇的是这样微小的电容器泄漏得更快——这是理所当然的——通常会在几个到几十个毫秒之内漏得一干二净。由于这个原因，这种存储器必须以极快的速度定时重写，这称为刷新。也正是因为这个原因，这种存储器也称为动态存储器（Dynamic Random Access Memory，DRAM）。

半导体存储器有一对孪生兄弟，除了RAM，还有ROM，它是“Read Only Memory”的缩写，意思是只能读的存储器。除了无法把数据写入每个存储单元以外，它和RAM一样，可以通过给出地址而读出任何一个存储单元的内容。

只读存储器最大的优势在于可以一直维持它所保存的内容，即使去掉电源之后也是这样。但是，如果既能在不需要电源的情况下不丢失数据，又能在需要的时候擦掉重写，可能更符合人的心意，所以只读存储器一直也在发展变化之中。最早的只读存储器是永久不能擦除重写的，它的内容在当初制造的时候就已经固化到里面了。很显然，如果用户买回来之后想自己往里面存储一些数据，就无能为力了。所以后来又发展出可编程只读存储器，用户可以根据自己的要求，对里面的内容重写一次。再往后，又发展出可擦除可编程只读存储器，可以根据自己的需要随时擦除重写，写完之后照样不会因为断电而丢失数据。这种只读存储器的一个典型产品是快闪存储器，从MP3播放器到手机里的存储卡，或者是你手中的U盘，用的都是这种材料。

只读存储器的用处很大，事实上，我们的计算机从来就没能离开过它。这里可以举一个非常有价值的例子，比如，可以用它来代替那些复杂的逻辑电路，以实现相同的功能。

我们知道，逻辑电路可以根据不同的输入产生不同的输出。比如全加器，当输入不同的三个比特时，就会在另一端输出一个“和”及一个进位，而译码器也是一个很好的例子。

传统上，所有的逻辑电路都是由与、或、非门构建的。取决于它的功能，逻辑电路可能很简单，只包含有限的几个与、或、非门，也可能很复杂，需要几十个、几百个，甚至更多。

想想看，对于一个特定的逻辑电路来说，每一组输入都会在它的另一端产生你所期望的、设计好的输出。如果把所有不同的输入看成是存储器地址，同时把它们对应的输出固化在存储单元里，岂不是可以取代传统的逻辑电路？

这的确是个好主意，这样一来，一个全加器就可以设计成具有 8 个存储单元、每个单元 2 位的只读存储器，如图 13.2 所示。

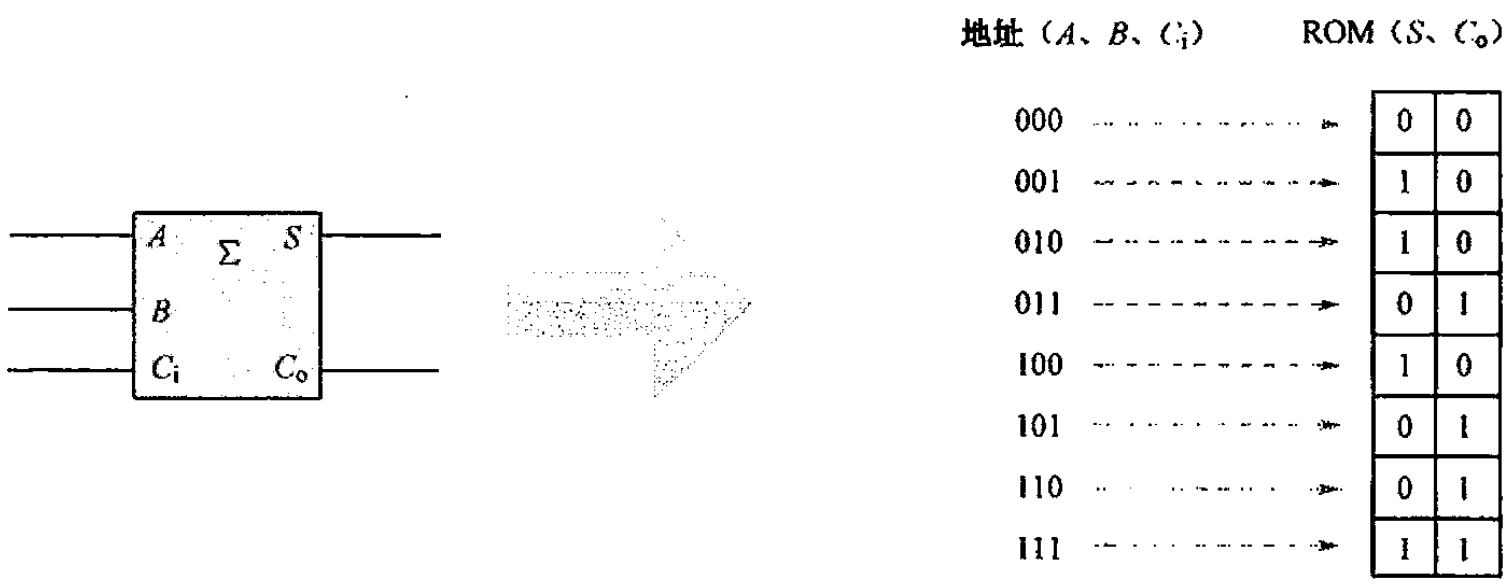

图 13.2　采用只读存储器来取代传统的逻辑门电路

用 ROM 来实现全加器的功能，这并不是一个十分复杂的例子。我们可以想象到，计算机内部的控制器是非常复杂的，因为它要应付一大堆指令，为它们产生不同的操作序列。最早，控制器全部采用逻辑门搭建而成，后来，在许多计算机上开始舍弃这种方法，转而采用 ROM，也就是我们在有些专业书上看到的“微代码 ROM”，它比我们这个全加器的例子要复杂成千上万倍。用只读存储器来代替传统的逻辑门电路，最大的好处就在于如果计算机的设计发生了变化，也能很方便地修改它的功能，而不会有拆掉所有的零件然后重新组装的麻烦，如图 13.3 所示。

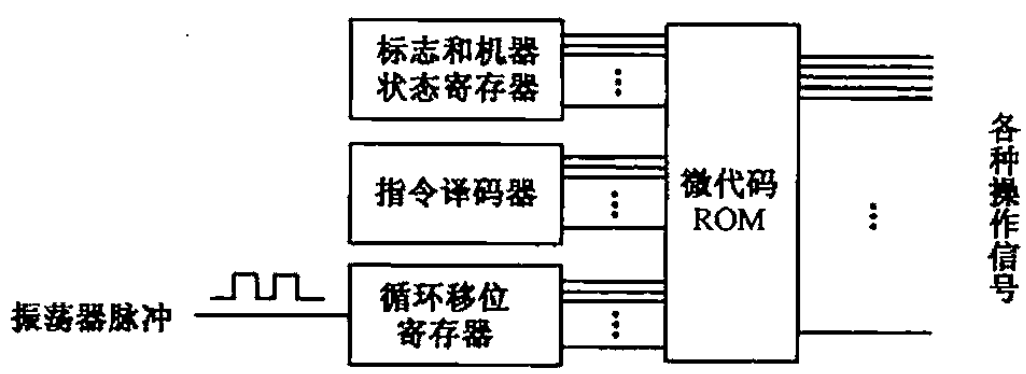

图 13.3　现代计算机的控制器结构

传统上，硬件就是制造出来并定了型的逻辑门组合，软件就是驱动这些硬件

的指令。显然，在集成电路时代，尤其是在可编程逻辑器件大行其道的现在，这两者之间的界限变得越来越模糊了。通过对 ROM 编程，可以根据需要改变它的输出，使它的功能发生变化，这就是可重构硬件。

一台计算机可以看成是紧密团结、有效协作的大家庭，它的核心成员包括存储器、运算器、控制器，以及一些七零八碎的门电路和触发器。存储器已经被集成化，心急的人们乘胜前进，把运算器和控制器也集成到一个单独的芯片里，这样就形成了人们常说的微处理器，这个名称非常恰当地表明了它的体积和具备的功能。微处理器的硅片很小，可能比火柴头还小，但是却包含了成千上万、几千万甚至几亿个晶体管。当然，微处理器必须配合其他电路才能发挥作用，所以要给它加个壳，封起来，向外引出一些导线。

微处理器更多地被称为中央处理器（Central Process Unit，CPU）。但后者似乎已经被专门用来指计算机上的微处理器。要知道科学技术发展得很快，而且越来越快，连手机、电视机、MP3、微波炉、电冰箱和汽车都用上了微处理器。尽管从表面上根本看不出来，但本质上它们都是一个个的微型计算机，通上电之后它们都在不停地工作，执行预先存储的程序指令，使你能够保存电话号码、玩手机游戏，或者给冰箱内的带鱼保鲜。

微处理器或者中央处理器都需要存储器及其他辅助设备才能工作并发挥作用，理所当然地，它需要向外部提供一些地址引线和数据引线，另外还包括一些控制信号线。最起码，它需要有引线从外部获得电源能量让自己活跃起来。最后，微处理器没有自己的振荡器，所以它需要从外部引进时钟信号。说来说去，一个现代的微处理器，在封闭好之后会有大量的引出线供外部与之相连，图 13.4 就是一个非常直观的实例。注意那些密密麻麻的小圆点，它们都是引线（脚）。

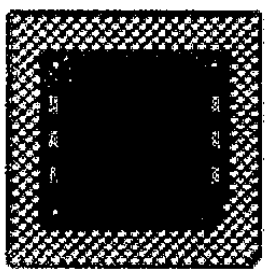

图 13.4　这是一款以前的中央处理器，中间的黑色部分是它的核心，周围分布的小圆点是它的引线（脚）

集成电路的发展速度很快，随着技术的进步，集成度也越来越高，工作速度越来越快，而价格则越来越便宜。就在写这本书之前，一个针尖上已经可以容纳 3 000 万个 45 纳米大小的晶体管；此外，现在的处理器上单个晶体管的价格仅仅是 1968 年晶体管价格的百万分之一。

除了集成度和工作速度之外，微处理器的另一个特点是它们都有各自的指令集。比如，对于甲公司生产的微处理器来说，它有一条指令：

1000100111011000

但是，对于乙公司生产的微处理器来说，这可能根本就不是一条指令，或者这条指令完全是另外一个意思，完成的是另外一种不同的工作。

这意味着，我们国家要生产自己的微处理器，指令集可能是一个需要慎重考虑的因素，除非它不打算运行现有的各种软件。

集成电路具有很多优点，但是就目前的现实情况来看还不可能完全替代采用独立零件的电路。一是有些东西，比如大的线圈，还没有办法集成；二是集成电路因为其微小的缘故，不能承受大电流和高电压，这就限制了它只能出现在像电子表、手机和其他一些更适合随身携带的设备中，或者大型设备中功率较小的那一部分电路里。如果电流过大，集成电路就会烧毁，就像熔断器所起的作用那样，世上再也找不出像集成电路这样构造复杂、制作精良的熔断器了。

13.3 流水线和高速缓存技术

在对微处理器有了一个大致的了解之后，我们可能需要再次回过头来，审视一下它和存储器之间协同工作的情况。

微处理器的速度很快，而且随着时间的推移和技术的进步，它会越来越快。尽管振荡器（时钟）的频率不能完全代表处理器的速度和性能，但还是具有参考意义。几十年前，处理器还在几兆赫兹（MHz）的频率下工作，但是现在这个数值已经提高到几个吉赫兹（GHz），增加了1 000倍。为了直观，我们通常更喜欢用每秒钟可以执行的指令数来衡量处理器的速度，这个数值在现实中的处理器上是几百万条指令每秒到几亿条指令每秒。

处理器当然有许多事情要做，但这些事情大都需要一系列步骤才能完成——从存储器取指令、译码、读/写操作数、移位、加减乘除，以及其他任何需要的操作。理想情况下，当前一个步骤完成时，后一个步骤应该紧随其后，中间不应该存在时间上的延迟。要是这样的话，我们手头上的绝大多数工作都应该能在瞬间完成，但是事实上却感觉不到这种情况的存在。处理器当然非常快，但它不是在孤立地工作，需要一大堆外围设备的配合，为它提供数据，遗憾的是这些东西都很慢。比如，每次你用U盘复制文件的时候，总能在屏幕上得到一个进度条，这不能怪处理器太慢，是你的U盘不够快。

U盘这种东西我们以后还会接着讨论，它显然不是我们现在的主要话题。我们知道，离处理器最近的是存储器，如果说处理器是加工厂的话，那么存储器就是原料和成品仓库。在后面的章节里，我们还会看到其他类型的存储器，但是在历史上，那些家伙都位于离处理器很远的机箱外面。为了加以区分，和中央处理器最近的存储器通常称为主存储器，或者内存储器，简称内存。

论访问速度，由触发器构成的内存（SRAM）是最快的，一般为几个纳秒。

与之相比，动态存储器（DRAM）就差些，访问速度可能是几十个纳秒，很大一部分原因在于它需要频繁地刷新，在此期间无法接待处理器的造访。

但是，与 SRAM 相比，DRAM 最大的优势在于它的高密度和低成本，使得我们可以花很少的钱就能买到一个大容量的内存。对于个人应用来说，这是一个很好的折中方案，既不会慢到无法忍受，同时又省了钱。问题是，处理器就很遭罪了，理想情况下只需要 7 个时钟周期的指令，可能实际上需要 50 个时钟周期才能完成，中间多出来的这些时钟周期，完全是为了等待内存而临时插入的（图 13.5）：

图 13.5　由于存储器的速度很慢，CPU 经常处于等待状态

处理器是比较昂贵的资源（当然，整台计算机都是），昂贵的东西应该保持忙碌才行，这样才对得起为它付出的时间、空间、金钱和电力成本。在这种情况下，为了让中央处理器满负荷地工作，流水线操作是个必然的选择。

从某种意义上来说，流水线是计算机里一个必要的恶魔，有人这样提到——它存在的理由是，要在中央处理器必须完成的工作和所需时间之间找一个平衡点。让我们来看一个例子。

我们已经知道，电流的速度是每秒钟 30 万公里。计算机的速度也很快，通常工作在纳秒级（ns）甚至皮秒级（ps），1 秒等于 1 000 000 000 纳秒或者 1 000 000 000 000 皮秒。所以，在 1 纳秒和 1 皮秒的时间里，电流只能分别向前传播 30 厘米和 0.3 毫米。

一旦在大脑中有了这样的概念，我们再来看看，假定有一个字节的数据 X 需要用两个步骤加工成 Z（图 13.6）：

图 13.6　数据加工的总时间是所有单元加工时间的总和

在这里，逻辑电路 1 和逻辑电路 2 分别用于完成那两个加工步骤。再假设，数据通过这两个逻辑电路需要相同的时间，都是 50 皮秒，那么，从 X 到 Z 的整个传输延迟就是 100 皮秒（两个逻辑电路之外的传输延迟可以忽略不计）。

而且，在数据加工期间，X 必须一直保持，直到 100 皮秒之后 Z 出现在右边的输出端，然后 X 才允许换上新的数据并开始下一轮的加工。只有这样，才能确保输出 Z 是稳定和正确的。

这意味着，每个 X 的加工时间都是 100 皮秒，同时也意味着，每隔 100 皮秒

我们才能从右边看到一个新的输出 Z。

为了改善整个电路的数据加工速度，流水线可能是一个不错的选择。因为 X 需要经过两次加工，所以这可以分成两级，每一级的加工结果都用寄存器保存。寄存器的作用是隔离两个加工级别，并使下一级的加工稳定可靠（图 13.7）：

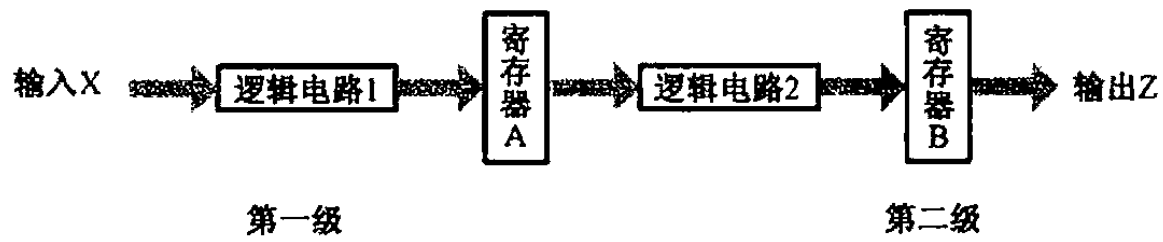

图 13.7　同样的设备，采用流水线可以缩短加工时间

一开始，X 被逻辑电路 1 加工。50 皮秒的延迟之后，数据到达寄存器 A 并被锁存。寄存器的动作需要一点点时间，为了便于说明，可以忽略不计。

紧接着，从第 50 皮秒处开始，第一级的加工结果由寄存器 A 保持，并被逻辑电路 2 加工。由于寄存器 A 的存在，输入 X 不再需要保持，第一级实际上是空闲的，它完全可以在第二级启动的同时加工新的数据。

同理，当第一个 X 的加工结果出现在寄存器 B 并被可靠地锁存时，第二个 X 正在被第二级加工，第三个 X 正在被第一级加工。尽管每个 X 的加工时间不变，还是 100 皮秒，但是我们却可以每隔 50 皮秒就能在寄存器 B 得到一个新的 Z，而不是以前的 100 皮秒，这正是流水线的妙处。

为了在处理器中使用流水线技术，可以将整个指令的执行过程分为三级：取指令、译码和执行，让它们重叠执行（图 13.8）。

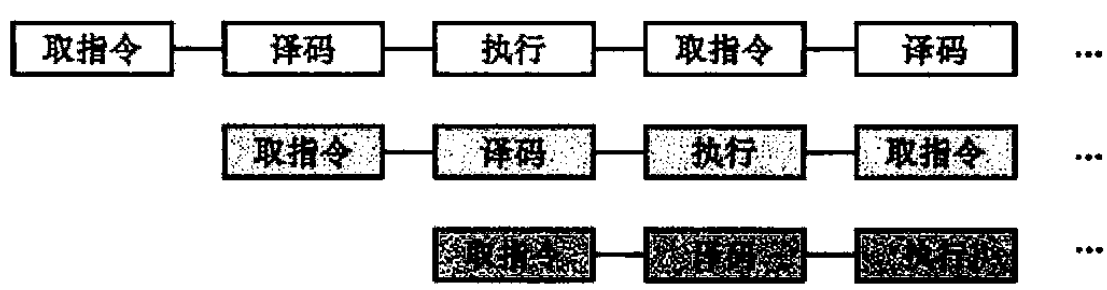

图 13.8　超标量体系结构

使用流水线技术，现代的计算机可以改进其设计和结构，允许在一个时钟周期内运行多条指令，这称为超标量体系结构。尽管看起来很了不起，但是流水线技术并不如我们想象中那样完美，有很多潜在的因素会影响它的效率。比如对于一条跳转指令，当它开始执行的时候，后面的两条指令已经进了流水线。在这种情况下，处理器只能清空流水线，从将要跳转到的目标地址那里重新读取指令。

解决这个问题的方法是为处理器增加分支预测功能。通过为处理器增加额外的电路，来预测将要发生的跳转。分支预测不会百分之百成功，但总比猝不及防要好得多。充其量是要清空流水线，使处理速度变慢，但不会比这更坏。

除了流水线，另一个被用来平衡处理器和内存速度的手段是使用高速缓存技术，字面上的意思是速度很快的缓冲存储器。类似于蓄水池，这种技术基于计算机运行的一个特点——局部性。通俗地说，局部性的意思是，程序在被执行的过程中常常会访问最近刚刚访问过的数据，或者该位置附近的数据。

我们知道，SRAM 的优点是速度快，但是制造成本很高，通常不作为内存使用。不过，好的东西不能拥有全部，来一点点应该还是可以的。基于局部性的原理，可以在处理器和内存之间放置一小块 SRAM，当处理器从一个新的内存地址开始执行时，将那一整片的东西都搬到这块 SRAM 中。这样一来，如果下次要访问的内容正好在 SRAM 中，就不用再到内存中去取，从而节省了时间（访问内存比访问 SRAM 需要更长的时间）。传统上，这一小块 SRAM 就是高速缓存，也就是我们经常在技术文章里看到的单词“Cache”。

在实际应用的时候，高速缓存有多种组织方案，但是从直观上来说，它好像两张表格，第一个表格存放的是从内存取来的一块块数据；第二个表格则存放每一个数据块所在的内存地址，如图 13.9 所示。

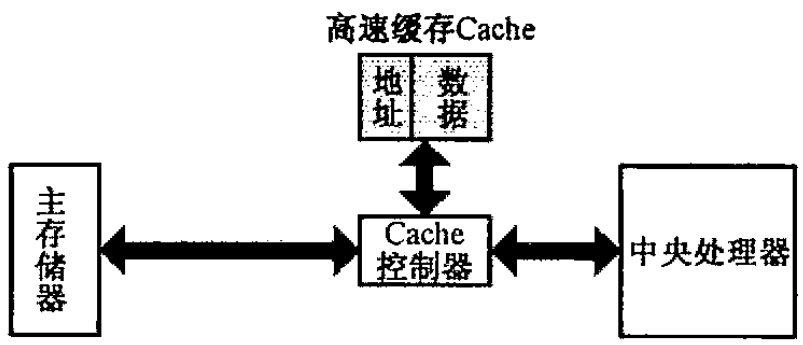

图 13.9　高速缓存示意图

高速缓存有一个控制器，即图中所示的 Cache 控制器。平时，中央处理器送出地址，要从内存中取数据时，Cache 控制器把该地址同高速缓存中的地址进行比较，以查明该数据是否在高速缓存中。由于大规模集成电路技术的发展，地址比较花不了多长时间，非常短暂。

如果要取的数据正好在高速缓存中，那么，很好，这称为“命中”，处理器可以直接拿到数据。处理器从高速缓存中取得数据的时间通常很短，称为“命中时间”。相反，如果数据不在高速缓存中，称为“不中”。

高速缓存不中是非常糟糕的，是最坏的情况。在这种情况下，处理器需要重新装载高速缓存（而不是硬着头皮去访问内存）。装载高速缓存也需要时间，即“不中惩罚”，这意味着执行一条指令需要更多的时间。

高速缓存是否能大幅度提升计算机的速度和性能，取决于命中的概率，也就是命中率。实际上，命中率受很多因素的影响，包括高速缓存的设计和软件的编写技巧，前者通常是硬件设计公司的机密，后者则需要软件工程师们的智慧。无论如何，这都不是本书的话题了。

13.4 掌上游戏机和手机就是计算机

最早的电子计算机出现在电子管时代，它们的体积都很大——这是没有办法的事，晶体管和集成电路的出现为时尚早。不过“大型机”的称呼倒是保留至今，尽管已经没有多少面积和体积上的内涵。

在那个时代，计算机在人们的心目中就像是卫星、火箭和大炮，不是为普通人发明的玩意儿，只有那些称得上是“问题”的问题才配在这样昂贵的家伙上计算一下。用它来上互联网？那个时候还没有互联网。玩游戏？那个时候也没有什么有趣的电子游戏，上机时间是非常宝贵的，分分秒秒都要付费，在这样的计算机上玩一个哪怕是现在看来很简单、弱智的游戏都会是一种罪过。所以，几乎没有人认为大众会需要这种东西，这是很自然的。

昂贵的、普通人用不上的东西不需要多造，但是政府和大企业又需要它。在这种情况下，大型机的目标就是计算能力更强、速度更快，甚至一台机器应该为一大堆用户服务，同时干好多工作，这就是所谓的分时、并行、多用户和多任务处理。为了这个目标，大家干得很起劲儿。很多我们现在依然在用的技术，包括一些看上去很新、很时髦的技术，其实在那个时候就已经有了，只是缺乏大规模普及的条件。不经意间，到了20世纪六、七十年代，集成电路发明了。

在实际拥有一部手机之前，有谁会想到手机的好处？又有谁会想到它可以看时间、打电话、上网、听音乐、看视频或者玩小游戏？几乎没有。甚至也没有人想到它会对我们如此重要。个人计算机也是这样，集成电路的发明使一部分人看到了电子计算机小型化的前景，但还不是十分清晰。在那个时代，认为每个人都会拥有一台计算机需要的不仅仅是超前的眼光，更要有直面被人骂成是白痴的勇气。这里的关键是，虽然集成电路可以缩小计算机的体积，但，为什么每个人都需要这么一样东西？

在这种情况下，难怪小型机的创始人奥尔森会在1979年十分肯定地说：“没有理由让某个人在家中配备一台计算机。”奥尔森是美国一个大计算机公司的总裁，还发明了小型机，本来就很有名，这下名气更大了。

在国内，个人计算机（Personal Computer，PC）以前叫微型计算机，简称微型机、微机，或者微电脑，显然，这已经成了历史名词。个人计算机兴起于20世纪70年代，那个时候，世界上第一个微处理器已经问世，但是功能很弱，所以这些个人计算机的鼻祖怎么看都像是玩具。

正如大家已经看到的那样，技术总是在不断地向前发展。随着微处理器的速度越来越快，功能越来越强，存储器的容量也更大，速度也更快，以往只在大型机上使用的先进技术，比如流水线和高速缓存，现在也可以用在个人计算机上以提高它的性能，以前只能在大型机和小型机上解决的任务，现在也可以在个人计

算机上完成。总之，它们之间的距离正在慢慢拉近。

越来越小型化，越来越强大，这就是未来的发展方向。不经意间，智能手机问世了，可以放在手上的电视机、音乐播放器、视频播放器和游戏机问世了。尽管发明这些东西所需要的理论和技术在几十年前就已经完备，但使它们小型化、微型化，也只有现在的技术条件才能做到。不管任何东西，只要稍微有一点智能的——从录音笔、微波炉调温装置、电冰箱，再到电子表、手机和游戏机，都需要用到微处理器和一小块内存储器，也需要一些编排精巧的指令。你能说，那些大家伙叫计算机，而这些东西就不叫计算机吗？